LOL-v2 低光增强色彩问题分析总结

Oct 14, 2026 · @jackchuan

ReDDiT 在 LOL-v2-Real 上颜色好，主要因为它把每张图的整体曝光和白平衡估得准，并且暗部饱和色不发灰；但它没有学到通用的色彩恒常性，换相机或输入带色偏时颜色会跟着输入走。

扩展到完整测试集后发现一个更基本的问题：同一场景的多次低光采集，输出的亮度和颜色并不一致。官方 Retinexformer 在 80 对同场景输入上的输出平均互差 ΔE00 为 4.14，24% 的对超过 5，且与对 GT 的误差基本无关（见“全测试集一致性”）。诊断表明，不一致几乎全部来自两次采集之间输入的逐通道增益和偏置差，模型把其中三成到六成带到了输出（见“不一致的来源”）。

背景与数据

- 测试集：LOL-v2-Real 测试集中的 5 张图（00739 楼梯；00749/00750 共用同一 GT；00751/00752 共用同一 GT），分辨率 600×400。后续扩展到完整测试集 100 张：按 GT 文件内容分组，正好是 43 个场景，每个场景 2–6 张不同的低光采集，共 80 对同场景输入。
- 方法与权重：CWNet、HVI-CIDNet、Retinexformer、Diff-Retinex、ReDDiT，均使用论文提供的 LOL-v2-Real 预训练权重直接推理，模型与权重均已逐一核对无误。ReDDiT 的随机种子固定，其 GT 校正系数约为 1（偏移 < 0.1）。
- 评价方式：PSNR、CIEDE2000 色差（ΔE00）、Lab 空间色度 C*、色相，以及用 GT 拟合的全局颜色校正（标量 / 逐通道 / 3×3 矩阵）。
- 分析脚本与结果文件位于 `F:\PythonProject\LLIE_Color\analysis\`。

现象一：暗部高饱和区域发灰

楼梯图（00739）左下角黄墙的亮度各方法都对，错在色度：B 通道从 GT 的 18 被抬到约 50，黄色变成灰棕。白墙和地面只是略淡，只有“又暗又饱和”的区域塑掉。

方法	黄墙均值 RGB	黄墙饱和度 S	暗+饱和像素色度保持率（5 张合计）	其他像素色度保持率
GT	(87, 68, 18)	0.79	1.00	1.00
ReDDiT	(89, 69, 22)	0.75	1.00	1.04
Retinexformer	(90, 75, 50)	0.44	0.63	0.85

方法	黄墙均值 RGB	黄墙饱和度 S	暗+饱和像素色度保持率（5 张合计）	其他像素色度保持率
Diff-Retinex	—	—	0.60	0.82
HVI	(80, 66, 52)	0.35	0.51	0.70
CWNet	(76, 61, 50)	0.34	0.54	0.65

“暗+饱和”指 GT 色度 C* > 30 且亮度 L < 45 的像素；保持率 = 输出色度 / GT 色度。按 GT 饱和度分档看，除 ReDDiT 外都是“越饱和丢得越多”，接近中性的像素反而被加色，符合回归模型“向平均色回归”的特征。

现象二：同一 GT 不同输入，色调不一致

同一 GT 对应的两张低光图，除 ReDDiT 外的方法输出色调会翻转。以全图平均 a*（负 = 偏青绿，正 = 偏品红）为例：

方法	00751 a*	00752 a*	两张输出间 ΔE00
GT	−4.8	−4.8	0
ReDDiT	−5.5	−4.0	3.89
HVI	−2.1	+2.0	8.70
Retinexformer	−3.9	+3.0	8.99
Diff-Retinex	−1.5	+2.5	8.03

最初的解释是两张低光图白平衡不同：用 GT 求的最优逐通道增益，00751 为 (30.6, 29.8, 37.1)，00752 为 (24.9, 32.4, 39.1)，R/G 从 1.03 降到 0.77。但验证实验把两张输入的白平衡和曝光对齐后，输出互差没有下降，只换噪声样本也不改变全局色调（见“验证实验”），成因仍待确定。这两组在全测试集里属于偏极端的例子，整体情况见下节。

全测试集一致性：同一场景的输出并不一致

测试集 100 张按 GT 文件内容（md5）分组，正好是 43 个场景、每个 2–6 张不同的低光采集，共 80 对同场景输入，理想输出应完全相同。官方 Retinexformer 的同组输出平均互差 ΔE00 为 4.14，24% 的对超过 5。



官方 Retinexformer 在 80 对里最不一致的两组：上排 00767/00768，色调差 15.2；下排 00743/00744，亮度差 ΔL* 9.0。右列为共用的 GT。

模型	全集 PSNR	对 GT ΔE00	输出互差 ΔE00	全局色调差	亮度差 ΔL*	局部互差 ΔE00	互差 > 5 的对
官方权重	22.79	8.20	**4.14**	1.64	1.56	2.95	24%
A 种子100	20.29	10.29	4.80	1.58	3.37	2.63	36%
A 种子 200	20.58	10.13	4.38	1.64	2.68	2.64	40%
B 种子100	20.31	10.41	4.49	1.75	2.77	2.63	30%
B 种子 200	20.60	10.34	4.73	1.66	3.27	2.50	38%
C	21.34	9.28	4.31	1.74	2.80	2.46	31%
D	20.73	10.17	5.51	1.25	4.69	2.63	42%

输出互差为同组两张输出的逐像素 ΔE00，80 对平均；全局色调差为两张输出全图平均 a*、b* 之差的模长；亮度差为全图平均 L* 之差的绝对值；局部互差为用 3×3+偏置把一张输出全局对齐到另一张后的 ΔE00。

- **长尾分布**：官方权重的色调差中位数 0.90、亮度差中位数 0.70，但 19% 的对色调差 > 3，16% 的对亮度差 > 3。现象二里的 00751/00752 在 80 对里排第 3，此前 5 张图偏向极端例子。

- **亮度和颜色一样不稳**：44% 的对色调差大于亮度差。合成扰动下亮度会被归一化，但真实同场景采集的亮度同样不一致，重训模型更明显（ΔL* 2.7–4.7）。
- **一致性与准确度基本无关**：各模型上“输出互差”与“两张对 GT ΔE00 均值”的相关系数为 −0.13 到 +0.28，PSNR 反映不了一致性。
- **训练随机性也会改颜色**：同一配置只换训练种子，同一张输入的输出色调差为 1.61（A）和 1.67（B），与换一次采集（1.58–1.75）相当；整体颜色本身缺少约束。
- **逐像素互差含噪声底**：局部互差 2.5–3.0，与实验 7 只换噪声样本的 2.4 接近。一致性的主指标应用全局色调差与亮度差，或降采样后再算 ΔE。
- **改善发灰的训练改动没有改善一致性**：所有重训组都比官方权重更不一致，D（关 mixup + 色度损失）最差，主要是亮度。重训模型本身比官方低 1.5–2.5 dB，这一条只作参考。

脚本：`analysis\consistency_eval.py`；结果：`analysis\consistency_results.txt`；图：`analysis\consistency_worst_pairs.png`。

不一致的来源：两次采集之间的增益和偏置差

同场景输出不一致几乎全部来自两次采集在输入颜色上的差别，即线性光空间里的逐通道增益和逐通道偏置；模型自身的随机不稳定可以忽略。诊断在全部 80 对测试输入和 137 对训练输入上完成。

输入几乎相同的 33 对（曝光差 < 0.1 档、输入色调差 < 1）上，官方权重的输出色调差只有 0.10、亮度差 0.12；其余 47 对分别是 2.72 和 2.57。前一节的长尾就是这些输入本身有差别的对。

模型	输出色调差与输入色调差的相关	多变量留一法 R^2	色偏传递斜率	较亮输入输出更亮的对	平均 ΔL*	ΔL* 与曝光差的相关
官方权重	**+0.92**	0.68	0.33	52%	−0.18	−0.08
A 种子 100	+0.86	0.43	0.27	50%	+1.72	+0.70
A 种子 200	+0.88	0.59	0.25	71%	+2.14	+0.52
B 种子 100	+0.90	0.70	0.27	56%	+1.33	+0.31
C	+0.80	0.44	0.25	62%	+1.50	+0.59
D	+0.78	0.47	0.12	68%	+3.10	+0.67

相关为 Spearman；输入色调差是两张输入各自用一个标量提亮到 GT 亮度后的平均 a*、b* 之差；多变量用 10 个不重复的输入差异特征解释输出色调差；色偏传递斜率为输出 (Δa*, Δb*) 对输入 (Δa*, Δb*) 的过原点斜率。

- **增益和偏置各有独立作用**：官方权重上，控制增益差后偏置差的偏相关为 +0.51，控制偏置差后增益差为 +0.64。加偏置后拟合残差下降超过 20% 的对，测试集占 36%，训练集占 54%。
- **可以排除的因素**：3×3 通道串扰（残差中位数只再降 2%）、非线性曲线（再降 1%）、低频彩斑（控制输入色调差后偏相关约为 0）、噪声样本（实验 7）。
- **传递比例**：按输入色调差分档，官方权重输出与输入色调差之比的中位数为 0.29–0.65，输入差别越大，比例越低。
- **亮度**：官方权重没有系统性泄漏，只是输入差别越大、输出亮度波动越大；重训模型有明显泄漏，较亮输入得到更亮输出，可能与 2.5 dB 的复现差距是同一个问题。
- **训练集**：689 张中只有 61 个场景有多次采集（151 张，137 对），其余 538 个场景各一张。训练对的差别比测试对大：曝光差超过 0.5 档的占 53%（测试 29%），输入色调差超过 3 的占 68%（测试 46%）。
- **对实验 4 的修正**：实验 4 只用 GT 求的逐通道增益做白平衡，没有处理偏置，而 00749/00750、00751/00752 恰好偏置很重；“不是白平衡造成的”应改为“单纯增益白平衡不够，增益加偏置才是主因”。
- **待做的干预实验**：把较暗输入分别按“只对齐曝光”“逐通道增益”“增益+偏置”“3×3+偏置”对齐到较亮输入后重新推理，看输出互差各降多少，把相关坐实为因果。合成数据上只用增益去掉 52% 的色调差，增益加偏置去掉 94%。

脚本：`analysis\diagnose_capture_difference.py`；结果：`Retinexformer\capture_diagnosis\summary.txt`、`test_pairs.csv`、`train_pairs.csv`；干预实验：`analysis\run_alignment_intervention.sh`。

输入端分析：颜色信息是否还在

楼梯黄墙的颜色在输入里是在的，是网络把它“校正”掉了。

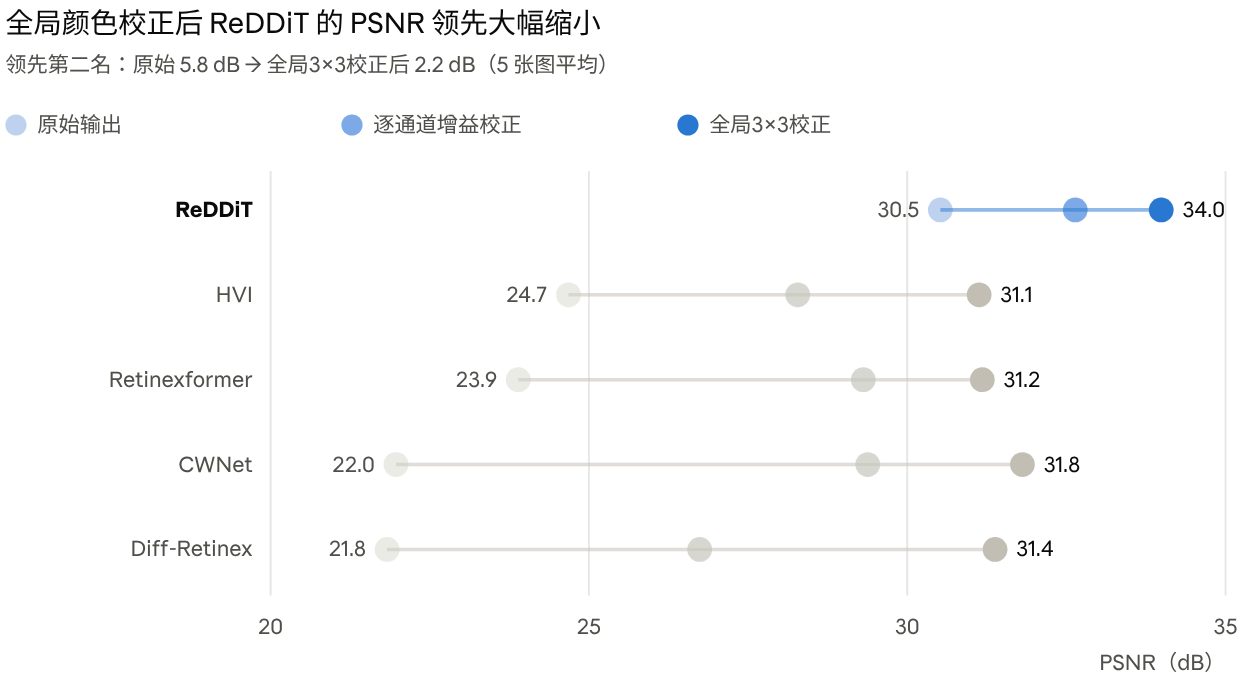
区域	R	G	B	B=0 的像素比例
黄墙 low（8bit）	3.83	3.40	0.17	87%
黄墙 GT（8bit）	87.3	68.2	18.6	0%

- 方向信息还在：B 几乎为 0 而 R、G 约为 3–4，输入里这块墙比 GT 还黄。但只剩很少的灰阶：整张图 B 通道只有 29 个不同取值，48% 的像素 ≤ 2。
- 不经任何网络的对照：在线性光下用 GT 求最优逐通道增益直接乘到 low 上，暗+饱和区色度保持率为 1.04（楼梯）和 1.00–1.04（00751/00752）。信息没有丢，变灰是网络造成的。
- 例外：00749/00750 暗部噪声 σ ≈ 5，色度信号 R−B 只有 0.8–2.8，信噪比 < 1，对照也只能恢复 0.60–0.72，这两张的颜色确实要靠先验补。

为什么网络会弄灰：楼梯图整张输入本身偏黄（均值 RGB = 9.3, 9.2, 4.5，B 需要的增益约 76×，R 约 53×）。网络学到“暗图偏黄 = 光源色偏，应去掉”，把黄色整体压低，真实的黄墙也被压掉。各方法输出 b* 比 GT 低：CWNet −12.3，HVI/Retinexformer/Diff-Retinex −4.4 至 −5.3，ReDDiT −1.0。最初的假设是“光源偏黄”与“物体本身是黄的”的歧义；验证实验显示这只是次要因素（见下文“验证实验”）。

误差分解：全局 vs 局部

各方法与 GT 的差距大部分是全局的。用 GT 为每张输出拟合一个全局颜色校正（逐通道增益 3 个参数，或 3×3 矩阵加偏置 12 个参数），各方法就都升到 31–32 dB。



第一次推理输出 · 5 张 LOL-v2-Real 测试图平均 · analysis\psnr_after_global_fit.txt

全局校正后剩下的差异才是局部细节和局部颜色的差异，对应现象一里的暗部发灰。这是用 GT 的上限对照，不是可部署的校正方法。

扰动实验：没有方法具备白平衡不变性

给 5 张低光图人为加上色偏和曝光变化（偏暖 R×1.15/B×0.85、偏冷、偏绿、整体 ×0.7、×1.4），再看输出相对原图结果的变化。表中为 b* 方向的色偏传递比例（100% = 完全照搬输入色偏）：

扰动	输入端 Δb*	ReDDiT	HVI	Retinexformer	Diff-Retinex
偏暖	+4.05	59%	40%	98%	121%
偏冷	−3.83	76%	43%	89%	84%

- 所有方法都会把相当一部分输入色偏带进输出。HVI 传递最少（40%–43%，偏绿方向 a* 为 49%），其次是 ReDDiT（59%–76%），Retinexformer 与 Diff-Retinex 基本照搬。HVI 一行用 `eval.py --unpaired --unpaired_weights best_PSNR --alpha 0.8 --gamma 0.9` 重跑，原图结果与官方评测输出接近（ΔE 1.4–4.4）。
- 曝光则都被归一化：输入 ΔL 为 −6.8 / +8.2，输出只变化约 0.5–4。
- 结论：这些方法学会了“把亮度拉到合适水平”，但都没有学会色彩恒常性。

脚本：`analysis\perturb_eval_all.py`，结果：`analysis\perturb_results.txt`。

ReDDiT 为何在 LOL-v2 上效果好

1. **主要优势：每张图的整体亮度和白平衡估得准。** 它比其他方法高出的 6–9 dB 里，大部分来自全局映射；给其他方法每张图修正 3–12 个全局参数，差距只剩约 2–3 dB（见上节图）。
2. **次要优势：暗部饱和色不发灰。** 暗+饱和区色度保持率约 1.0，其他方法 0.5–0.6。生成模型从 GT 分布采样，而不是像回归模型那样输出平均色。
3. **这种“准”是针对该数据集的。** 扰动实验中它会把 59%–76% 的输入色偏带进输出，还不如 HVI（40%–43%）。它记住的是 LOL-v2-Real 这台相机、这条 ISP、这种光照下的色调规律；测试集和训练集拍摄条件一致，所以分数高。

对比说明：Diff-Retinex 同为扩散模型，全局 3×3 校正后 PSNR 达 31.38，局部能力不差；它的短板全在全局，输出亮度在 GT 的 0.87–1.33 倍之间波动。是否为扩散模型并不决定颜色好坏，关键是全局曝光和白平衡是否被约束住。

泛化能力与 SID 测试

拍摄条件与 LOL-v2-Real 相近时 ReDDiT 会表现很好；一旦相机、ISP、噪声水平或输入色偏变化，颜色会跟着输入走。

SID 测试（00076 场景，10 帧 0.1s 短曝光，来自 Retinexformer 提供的预处理 npy 版本，960×512）：

	平均 RGB（8bit）	说明
short 输入	(65, 26, 53)	已半提亮，本身偏品红
ReDDiT 输出	(83, 31, 94)	照搬输入的品红色再提亮，有涂抹感
long GT	(121, 136, 139)	正常中性偏青

- 这份 SID 的 short 图自带特性：GT 最暗 5% 区域约为 (24, 26, 24)，short 却是 (44, 9, 38)，R/B 有固定正偏置；帧间噪声标准差 R/B 约 42、G 约 19。这不是转换错误。
- 三点都超出 LOL-v2-Real 训练分布：亮度约 48/255（LOL 低光约 10/255）、自带色偏、噪声大好几倍。加上不具备白平衡不变性，输出品红是预期内的。
- 这个测试偏离太远，只算泛化能力的下限。更直接的检验：用 LOL-v2 权重跑拍摄条件不同、亮度与 LOL 相近的低光图（LOL-v1、LSRW、DICM、LIME 等），看输出颜色是否跟着输入色偏走。

诊断图：`analysis\sid_00076_diagnosis.png`。

验证实验：歧义与白平衡解释只得到部分支持

四个预测里只有“噪声导致发灰”在 HVI 和 Retinexformer 上得到明确支持；“光源/物体歧义”只解释了很小一部分，“色调不一致来自输入白平衡”在只做增益白平衡时不成立（后续诊断表明增益加偏置才是主因）。

实验	预测	结果	判定
1 全图去色偏	黄墙色度保持率明显回升	HVI 0.46→0.51，Retinexformer 0.54→0.60，Diff-Retinex 0.40→0.51，ReDDiT 0.91→0.97	仅小幅支持
2 仅背景去色偏	黄墙随背景变化	与实验 1 几乎相同（0.53 / 0.61 / 0.53 / 0.97）	上下文有影响但很小
3 暗/噪声分离	无噪声保持率更高	HVI 0.65 vs 0.46，Retinexformer 0.70 vs 0.55；Diff-Retinex 0.59 vs 0.66，ReDDiT 0.60 vs 0.90	回归模型支持；扩散模型反向

实验	预测	结果	判定
4 统一白平衡	两张输出互差下降	互差基本不变甚至变大（如 Retinexformer 7.96→9.44，ReDDiT 3.58→6.52）	推翻（仅指单纯增益白平衡）

修正后的理解：

- **发灰**：全局色偏带来的歧义只贡献约 0.05–0.1；噪声对 HVI、Retinexformer 贡献约 0.15–0.2。但即使输入无噪声、色偏已去掉，它们仍只保留 0.6–0.7，说明模型本身就系统性地压低饱和度，与输入无关。这是发灰的主因。
- **色调不一致**：不是单纯的增益白平衡造成的；后续 80 对上的诊断表明主因是增益加偏置（见“不一致的来源”）。白平衡对齐后两张输出仍差 ΔE 4–10，第二轮验证显示曝光对齐也不能消除差异（见下表）。
- **扩散模型在无噪声输入上反而变差**（ReDDiT 0.90→0.60），说明它们依赖训练时见过的噪声形态，干净的合成暗图对它们是分布外输入。这也提醒：实验 3 对扩散模型的结论不可直接解读。

第二轮（实验 5–6）：

暗+饱和色度保持率	无噪声+无色偏	无噪声+有色偏	有噪声+无色偏	有噪声+有色偏	真实低光
HVI	0.68	0.65	0.53	0.46	0.56
Retinexformer	0.78	0.70	0.64	0.55	0.63
Diff-Retinex	0.63	0.59	0.69	0.66	0.55
ReDDiT	0.54	0.60	0.96	0.90	0.96

- 实验 5 支持“模型本身压低饱和度”：输入既无噪声又无色偏时，HVI 仍只保留 0.68、Retinexformer 0.78。对这两个回归模型，噪声再拉低约 0.15，色偏只拉低 0.03–0.08。
- ReDDiT 在有噪声输入上保持率约 0.9–0.96，不存在固有压饱和度的问题；但输入一旦无噪声就降到 0.54–0.60，它的色彩恢复和去噪是一起学到的，依赖训练分布中的噪声形态。
- 实验 6 推翻曝光解释：亮度对齐（约 10%）后两张输出互差基本不变（如 HVI 7.78→7.77、ReDDiT 4.50→4.50）。白平衡和曝光都排除后，剩下的最可能是两次拍摄的噪声不同，即模型输出对噪声细节敏感；Diff-Retinex 还叠加了自身采样的随机性（同一输入重跑就有 ΔE 0.9–3.3）。

脚本：`analysis\make_verify2_inputs.py`、`analysis\verify2_eval.py`；结果：`analysis\verify2_results.txt`。

第三轮（实验 7：只换噪声样本）：随机噪声只影响局部像素，不影响全局色调。

- 换噪声种子后逐像素 ΔE 为 2.4–4.6，但全图平均 a*/b* 变化只有 0.02–0.03（HVI、Retinexformer）。真实成对图的全局色调差则是 4–7，且白平衡、曝光对齐后仍在。
- 此前实验 4–6 用的是逐像素 ΔE，混入了局部噪声差异；改用全局色调差（`analysis\tone_pair_results.txt`）后结论不变：单纯增益白平衡、曝光、随机噪声都不是原因。
- 新线索（已在 80 对上验证：① 成立，② 在控制输入色调差后没有独立作用，见“不一致的来源”）：① 同组两张低光图之间不只是增益不同，还有逐通道偏置差异（00749→00750 的 R 通道偏置明显与 G/B 不同），全局增益白平衡消不掉；② 真实噪声的低频色度分量（彩色斑块）是合成噪声的 3–5 倍，它看起来像局部色偏。

脚本：`analysis\make_verify3_inputs.py`、`analysis\verify3_eval.py`、`analysis\tone_pair_eval.py`。

局限：白平衡增益由 GT 求得，合成噪声为高斯噪声，且只有 5 张图。脚本：`analysis\make_verify_inputs.py`、`analysis\verify_eval.py`；结果：`analysis\verify_results.txt`。

改进实验：关闭 mixup 能消除模型本身的压饱和度

在 Retinexformer 上从头训练 4 组（官方配置 15 万次迭代，单卡各约 7.5 小时）：A 官方配置重训、B 关闭 mixup、C 加色度损失、D 两者都做。代码见 `Retinexformer/basicsr/models/losses/color_losses.py` 与 `Options/color_exp/`。

组	全测试集 PSNR（最后一步）	后期 10 次验证均值	5 张难例暗饱和保持	楼梯黄墙	合成无噪声输入保持
官方权重	22.79	—	0.63	0.54	0.70
A 官方配置重训	20.29	20.34	0.71	0.60	0.65
B 关闭 mixup	20.31	20.35	**0.80**	**0.75**	**0.96**
C 色度损失	21.34	**21.25**	0.78	0.67	0.66
D 关 mixup + 色度损失	20.73	20.71	0.75	0.64	0.86

- **mixup 是模型本身压饱和度的主要来源**：在无噪声合成输入上，关闭 mixup 的两组（B 0.96、D 0.86）都明显高于开启的两组（A 0.65、C 0.66）。mixup 把两张 GT 线性混合，训练目标本身变灰。
- **色度损失提升了 PSNR，但没有解决难例发灰**：C 后期稳定比 A 高约 0.9 dB，但合成输入保持率不变、难例 ΔE 反而变差。

- **全测试集上发灰并不普遍**：官方权重暗饱和保持率 0.86，重训 A 已达 0.99；之前 5 张图偏向最严重的例子。
- **不确定性**：重训 A 比官方权重低 2.5 dB（即使取验证最佳也只有 20.98）；训练中验证 PSNR 在相邻检查点间波动约 ±0.5–1 dB；每组只训了一次。数据：`analysis\color_exp_detail.txt`。

重复实验（种子 200）：方向复现，幅度比第一次小。

指标（5 张难例）	A 种子100	A 种子200	B 种子100	B 种子200
暗饱和保持	0.71	0.67	0.80	0.76
楼梯黄墙	0.60	0.56	0.75	0.65
ΔE00	11.67	12.25	9.42	11.41

- 两个种子下关闭 mixup 都更好：难例保持率约 +0.09，ΔE 更低。
- 合成输入上第一次的 0.65→0.96 未能同样复现：种子 200 在“无噪声+无色偏”输入上为 0.69→0.78。两次用的合成输入不同（第一轮带色偏、第二轮无色偏），不能直接对比。
- 在带噪声的合成输入上，B 反而略低于 A（两个种子都是）。

统一用第二轮合成输入（无色偏）后：无噪声时 A→B 为 0.60→0.92（种子 100）、**0.69→0.78**（种子 200），两次都是 B 更高但幅度差别大；有噪声时 0.66→0.67、0.75→0.64，关闭 mixup 没有帮助。

全测试集与难例子集（100 张 GT）：关闭 mixup 不损失 PSNR，在难例上两个种子都稳定改善。

组	全集 PSNR	全集 ΔE00	难例 PSNR	难例 ΔE00	难例暗饱和保持
官方权重	22.79	8.20	24.46	7.06	0.654
A 种子100	20.29	10.29	22.17	8.65	0.818
A 种子200	20.58	10.13	20.89	9.73	0.814
B 种子100	20.31	10.41	23.29	7.95	0.921
B 种子200	20.60	10.34	22.57	8.05	0.855
C	21.34	9.28	22.78	7.79	0.872
D	20.73	10.17	24.14	6.52	0.862

- 难例 = 官方权重暗饱和保持率 < 0.8 且此类像素 ≥ 2000 的图，共 9 张（00694 00695 00708 00709 00739 00740 00749 00757 00767），其中有近乎重复的场景，实际约 6–7 个场景。

- 关闭 mixup：全集 PSNR 不变（20.29→20.31、20.58→20.60）；难例上保持率 +0.04–0.10、PSNR +1.1–1.7 dB、ΔE 降 0.7–1.7，两个种子方向一致。
- 色度损失（C）：全集 PSNR 比 A 高约 0.8 dB，但只有一个种子，待复现。
- 所有重训模型的全集 PSNR 都比官方权重低 1.5–2.5 dB，改进只能相对自己的重训基线来说。数据：`analysis\color_exp_full.txt`。

推理设置与待办

所有方法均使用各自论文发布的 LOL-v2-Real 预训练权重，模型与权重已逐一核对无误。做一致性评测时要扣除的是各方法自身的推理随机性：同一输入重跑一次，输出之间的差异如下（实验 7，5 张合成输入平均）。

方法	同一输入重跑 ΔE00	说明
Retinexformer	0.00	确定性
HVI	0.00	确定性
ReDDiT	1.14	扩散采样随机性
Diff-Retinex	3.62	扩散采样随机性

扩散模型的同场景互差需要和这个下限一起报告，并做多次采样。ReDDiT 的两个推理脚本预处理不同：`test.py` 把输入 padding 到 608×416，`test_unpaired.py` resize 到 592×400，结果接近（30.52 / 30.00 dB），比较时统一用同一个脚本。

- [x] ~~核对各方法的权重与推理参数（已确认无误）~~
- [x] ~~在完整测试集上按 GT 分组，评测 Retinexformer 官方权重与 6 个重训模型的同场景一致性（43 个场景 / 80 对）~~
- [x] ~~对同组输入拟合“只用增益”和“增益加偏置”等全局模型，确定不一致的来源（结论：增益加偏置）~~
- [x] ~~按 GT md5 检查 LOL-v2 训练集是否也是多采集分组（61 个场景 / 137 对）~~
- [ ] 在服务器上跑干预实验（`run_alignment_intervention.sh`），确认增益加偏置对齐能否消除输出不一致
- [ ] 检查训练集与测试集是否有重复场景（GT md5）
- [ ] 用训练集 137 对的曝光、增益、偏置分布构造扰动，从官方权重微调一致性训练
- [ ] 用 HVI、CWNet、Diff-Retinex、ReDDiT 跑完整 100 张测试集并评测一致性；ReDDiT、Diff-Retinex 各采样至少 3 次

- [ ] 在完整测试集上重跑全局/局部分解和扰动实验，确认 5 张图上的趋势
- [ ] 用 LOL-v2 权重在 LOL-v1 / LSRW / DICM / LIME 上检验颜色泛化，在 MILL（相机固定、只改光照强度）上检验同场景一致性